ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN

Project 3: Linear Regression

MTH00057 - Toán ứng dụng và thống kê cho Công nghệ thông tin

Giảng viên hướng dẫn:

Nguyễn Đình Thúc

Trần Hà Sơn

Nguyễn Văn Quang Huy

Nguyễn Ngọc Toàn

Sinh viên thực hiện:

Trần Phụng Đình (23127527)

Ngày 14 tháng 8 năm 2025

Mục lục

1 Thông tin sinh viên **1**

2 Ý tưởng thực hiện **1**

2.1 Tổng quan về đồ án . . . 1

a) Input, Output của đồ án . . . 1

b) Mục tiêu . . . 1

2.2 Ý tưởng giải quyết . . . 2

3 Chi tiết thực hiện **2**

3.1 Cấu trúc chương trình . . . 2

a) Thư viện đã sử dụng . . . 3

3.2 Các hàm đã xây dựng . . . 3

a) `mse(y_true, y_pred)` . . . 3

b) `train_linear_regression(X, y)` . . . 3

c) `print_regression_formula(theta, feature_names)` . . . 3

d) `exploratory_data_analysis(X_train, y_train, feature_names, target_name)` . . . 4

e) `cross_validate_single_feature(X_df, y_series, feature_name, k=5)` . . . 4

f) `cross_validate_model(X_df, y_series, feature_list, transform_fn=None, k=5)` . . . 4

3.3 Phân tích khám phá dữ liệu . . . 5

a) Quy trình tiền xử lý dữ liệu . . . 5

b) Quy trình khai phá dữ liệu (EDA) . . . 6

c) Hours Studied (Số giờ học) . . . 9

d) Previous Scores (Điểm trước đó) . . . 9

e) Extracurricular Activities (Hoạt động ngoại khóa) . . . 9

f) Sleep Hours (Số giờ ngủ) . . . 9

g) Sample Question Papers Practiced (Số đề mẫu đã luyện) . . . 9

3.4 Các mô hình hồi quy tuyến tính . . . 11

a) Mô hình sử dụng toàn bộ đặc trưng (yêu cầu 2a) . . . 11

b) Chọn đặc trưng tốt nhất với K-fold Cross Validation (yêu cầu 2b) . . . 13

4 Kết quả và kết luận **17**

5 Tài liệu **17**

6 Acknowledgement **17**

1 Thông tin sinh viên

Họ tên	MSSV	Email	Lớp
Trần Phụng Đình	23127527	tpdinh23@clc.fitus.edu.vn	23CLC01

2 Ý tưởng thực hiện

2.1 Tổng quan về đồ án

Đồ án này tập trung vào việc xây dựng và đánh giá các mô hình hồi quy tuyến tính (**Linear Regression Model**) nhằm dự đoán *Student Performance Index* (chỉ số thành tích học tập) của sinh viên dựa trên 5 đặc trưng đầu vào:

1. Hours Studied (*Số giờ học*)
2. Previous Scores (*Điểm số trước đây*)
3. Extracurricular Activities (*Hoạt động ngoại khóa*)
4. Sleep Hours (*Số giờ ngủ*)
5. Sample Question Papers Practiced (*Số đề thi mẫu đã luyện tập*)

Bài toán yêu cầu thực hiện **phân tích khám phá dữ liệu** (**Exploratory Data Analysis (EDA)**), huấn luyện nhiều biến thể của **mô hình hồi quy**, và đánh giá hiệu quả dự đoán thông qua chỉ số **Mean Squared Error – MSE**.

a) Input, Output của đồ án

- **Input**:
  - `train.csv` chứa 9000 mẫu dữ liệu đã được tiền xử lý.
  - `test.csv` chứa 1000 mẫu dữ liệu để kiểm tra mô hình.
- **Output**:
  - Các mô hình hồi quy tuyến tính được huấn luyện theo yêu cầu 2a, 2b, 2c.
  - Các công thức hồi quy thể hiện mối quan hệ giữa biến mục tiêu và các đặc trưng.
  - Bảng kết quả MSE trên tập kiểm tra cho từng mô hình.
  - Báo cáo phân tích và nhận xét về toàn bộ các mô hình đã xây dựng.

b) Mục tiêu

Mục tiêu chính của đồ án:

- Hiểu và áp dụng quy trình phân tích dữ liệu, tiền xử lý và xây dựng mô hình dự đoán.
- So sánh hiệu quả giữa các mô hình hồi quy tuyến tính với tập đặc trưng khác nhau.
- Đề xuất và thử nghiệm các biến thể mô hình nhằm cải thiện độ chính xác dự đoán.

2.2 Ý tưởng giải quyết

Quy trình thực hiện đồ án được đề xuất như sau:

1. **Phân tích khám phá dữ liệu (EDA)**: Tiến hành thống kê mô tả (**Descriptive Statistics**), kiểm tra phân phối dữ liệu, đánh giá mối tương quan giữa các đặc trưng và trực quan hóa dữ liệu bằng `box plot`, `scatter plot` và `heatmap`.
2. **Xây dựng mô hình hồi quy tuyến tính cơ bản**: Huấn luyện mô hình sử dụng toàn bộ 5 đặc trưng và đánh giá trên tập kiểm tra.
3. **Tối ưu hóa lựa chọn đặc trưng**: Xây dựng các mô hình chỉ sử dụng một đặc trưng, áp dụng **k-fold Cross Validation** ($k \geq 5$) để chọn ra đặc trưng cho kết quả tốt nhất.
4. **Thiết kế mô hình nâng cao**: Tạo ra các mô hình mới dựa trên kết hợp hoặc biến đổi đặc trưng (chuẩn hóa, bình phương, tạo đặc trưng tổng hợp), xây dựng tối thiểu 3 mô hình và chọn mô hình tốt nhất dựa trên MSE trung bình qua Cross Validation.
5. **Đánh giá và so sánh kết quả**: Tổng hợp kết quả, so sánh giữa các mô hình và đưa ra giải thích logic cho mô hình đạt hiệu quả cao nhất.

3 Chi tiết thực hiện

3.1 Cấu trúc chương trình

- `Đọc dữ liệu tập train/test`
- **Hàm chung:**
  - `mse(y_true, y_pred)`: Tính giá trị Mean Squared Error.
  - `train_linear_regression(X, y)`: Huấn luyện mô hình hồi quy tuyến tính.
  - `print_regression_formula(theta, feature_names)`: In công thức hồi quy.
- **Hàm phục vụ yêu cầu phân tích dữ liệu:**
  - `exploratory_data_analysis(X_train, y_train, feature_names, target_name)`: Phân tích khám phá dữ liệu.
- **Đánh giá mô hình:**
  - 2a. Xây dựng mô hình hồi quy cho toàn bộ đặc trưng: gọi hàm train_linear_regression, print_regression_formula và hàm tính mse
  - `2b. cross_validate_single_feature(X_df, y_series, feature_name, k=5)`: Cross-validation cho một đặc trưng.
  - `2c. cross_validate_model(X_df, y_series, feature_list, transform_fn=None, k=5)`: Cross-validation cho mô hình nhiều đặc trưng.

a) Thư viện đã sử dụng

- `numpy`: Tính toán ma trận, vector, tính toán MSE.
- `pandas`: Đọc và xử lý dữ liệu CSV.
- `matplotlib`: Vẽ biểu đồ phân tích dữ liệu.
- `seaborn`: Vẽ biểu đồ phân tích dữ liệu.

3.2 Các hàm đã xây dựng

Dưới đây là mô tả chi tiết từng hàm:

a) `mse(y_true, y_pred)`

- **Input:**
  - `y_true`: Giá trị thực tế (mảng hoặc Series).
  - `y_pred`: Giá trị dự đoán (mảng hoặc Series).
- **Output:** Một số thực đại diện cho lỗi bình phương trung bình.
- **Mô tả:** Hàm tính trung bình của bình phương hiệu giữa giá trị thực tế và giá trị dự đoán.
- **Ý tưởng thực hiện:** Sử dụng phép trừ và toán tử mũ 2 cho từng phần tử, sau đó lấy trung bình bằng `np.mean`.

b) `train_linear_regression(X, y)`

- **Input:**
  - `X`: Ma trận đặc trưng (numpy array).
  - `y`: Vector mục tiêu.
- **Output:** Vector trọng số θ của mô hình hồi quy tuyến tính.
- **Mô tả:** Hàm huấn luyện mô hình hồi quy tuyến tính bằng công thức nghiệm đóng.
- **Ý tưởng thực hiện:** Áp dụng công thức $(X^T X)^{-1} X^T y$ bằng `np.linalg.inv` và `np.dot`.

c) `print_regression_formula(theta, feature_names)`

- **Input:**
  - `theta`: Hệ số hồi quy.
  - `feature_names`: Danh sách tên đặc trưng.
- **Output:** Không trả về; in công thức hồi quy ra màn hình.
- **Mô tả:** Hàm in phương trình hồi quy dưới dạng chuỗi.
- **Ý tưởng thực hiện:** Sử dụng vòng lặp kết hợp `f-string` để ghép hệ số với tên đặc trưng.

d) `exploratory_data_analysis(X_train, y_train, feature_names, target_name)`

- **Input:**
  - `X_train`: Dữ liệu huấn luyện (đặc trưng).
  - `y_train`: Dữ liệu mục tiêu.
  - `feature_names`: Danh sách tên đặc trưng.
  - `target_name`: Tên biến mục tiêu.
- **Output:** Biểu đồ và thống kê mô tả dữ liệu.
- **Mô tả:** Hàm phân tích dữ liệu bằng các biểu đồ trực quan và thống kê mô tả.
- **Ý tưởng thực hiện:** Sử dụng histogram, boxplot, heatmap, scatter từ `matplotlib` và `seaborn`.

e) `cross_validate_single_feature(X_df, y_series, feature_name, k=5)`

- **Input:**
  - `X_df`: DataFrame chứa các đặc trưng.
  - `y_series`: Series mục tiêu.
  - `feature_name`: Tên đặc trưng để kiểm tra.
  - `k`: Số lượng fold trong cross-validation.
- **Output:** Giá trị lỗi trung bình qua các fold.
- **Mô tả:** Hàm kiểm tra mô hình với một đặc trưng bằng cross-validation.
- **Ý tưởng thực hiện:** Chia dữ liệu thành k phần, huấn luyện và kiểm tra lặp lại, tính MSE trung bình.

f) `cross_validate_model(X_df, y_series, feature_list, transform_fn=None, k=5)`

- **Input:**
  - `X_df`: DataFrame chứa các đặc trưng.
  - `y_series`: Series mục tiêu.
  - `feature_list`: Danh sách đặc trưng cần dùng.
  - `transform_fn`: Hàm biến đổi dữ liệu (nếu có).
  - `k`: Số lượng fold trong cross-validation.
- **Output:** Giá trị lỗi trung bình qua các fold.
- **Mô tả:** Hàm cross-validation cho mô hình nhiều đặc trưng, có thể kết hợp biến đổi dữ liệu.
- **Ý tưởng thực hiện:** Nếu có `transform_fn` thì áp dụng lên đặc trưng, ghép ma trận bằng `np.hstack`, chia dữ liệu theo k fold và tính MSE trung bình.

3.3 Phân tích khám phá dữ liệu

a) Quy trình tiền xử lý dữ liệu

Mục tiêu: Mục tiêu của bước tiền xử lý (*data preprocessing*) là biến đổi tập dữ liệu thô ban đầu thành dạng *sạch* và *thích hợp* cho mô hình hồi quy tuyến tính. Các tác vụ tiền xử lý đảm bảo:

- Loại bỏ hoặc giảm thiểu lỗi dữ liệu (missing values, định dạng sai).
- Đưa tất cả đặc trưng về cùng hệ biểu diễn nhất quán.
- Chuyển đổi các biến phi số thành dạng số có thể xử lý bằng đại số tuyến tính.

Bước 1: Đọc dữ liệu và xác định thành phần. Dữ liệu được cung cấp dưới dạng hai tệp:

- `train.csv`: 9000 mẫu, dùng để huấn luyện mô hình.
- `test.csv`: 1000 mẫu, dùng để đánh giá mô hình.

Mỗi mẫu gồm $p = 5$ đặc trưng đầu vào và 1 biến mục tiêu (chỉ số thành tích sinh viên). Các đặc trưng:

1. `Hours Studied`: số giờ học mỗi tuần (*numeric, continuous*).
2. `Previous Scores`: điểm số trước đó (*numeric, continuous*).
3. `Extracurricular Activities`: tham gia hoạt động ngoại khoá (*categorical, binary*).
4. `Sleep Hours`: số giờ ngủ mỗi ngày (*numeric, continuous*).
5. `Sample Question Papers Practiced`: số lượng đề luyện tập (*numeric, integer*).

Biến mục tiêu: `Performance Index` (*numeric, continuous*).

Bước 2: Kiểm tra và xử lý dữ liệu thiếu.

- Sử dụng `isnull().sum()` để đếm số giá trị `NaN` trong mỗi cột.
- Kết quả: none, không phát hiện giá trị thiếu trong bất kỳ đặc trưng nào $\Rightarrow$ không cần thao tác điền khuyết (*imputation*).

Bước 3: Chuyển đổi biến phân loại (*categorical encoding*). `Extracurricular Activities` ban đầu là biến dạng chuỗi (`'Yes'` / `'No'`). Ta chuyển đổi sang giá trị nhị phân:

$$\text{'Yes'} \mapsto 1, \quad \text{'No'} \mapsto 0.$$

Việc mã hoá này giúp:

- Dữ liệu sẵn sàng cho mô hình hồi quy tuyến tính (chỉ xử lý số).
- Giữ nguyên ý nghĩa: 1 thể hiện có tham gia hoạt động ngoại khoá, 0 là không.

Bước này đã được thực hiện sẵn, nên ta bỏ qua

Bước 4: Xác định tập huấn luyện và tập kiểm tra. Theo đề bài, dữ liệu đã được chia sẵn theo tỷ lệ 90% huấn luyện, 10% kiểm tra. Do đó:

- Không cần chia lại dữ liệu (tránh sai lệch phân phối).
- Giữ nguyên thứ tự và cấu trúc của tệp `train.csv` và `test.csv`.

Bước 5: Tách đặc trưng và biến mục tiêu.

- Tập huấn luyện:

$$X_{\text{train}} \in \mathbb{R}^{9000\times 5}, \quad y_{\text{train}} \in \mathbb{R}^{9000\times 1}.$$

- Tập kiểm tra:

$$X_{\text{test}} \in \mathbb{R}^{1000\times 5}, \quad y_{\text{test}} \in \mathbb{R}^{1000\times 1}.$$

Các mảng đặc trưng X được chuyển sang dạng *NumPy array* để thuận tiện cho thao tác đại số tuyến tính khi huấn luyện mô hình:

$$\tilde{X} = \begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}$$

Trong đó, cột đầu tiên là *bias term* (toàn giá trị 1).

Kết quả. Sau bước tiền xử lý, dữ liệu ở trạng thái:

- Hoàn toàn số hoá.
- Không chứa giá trị thiếu.
- Sẵn sàng cho phân tích khám phá dữ liệu (EDA) và huấn luyện mô hình hồi quy tuyến tính.

(Đưa biểu đồ phân bố, boxplot, heatmap tương quan, nhận xét từng đặc trưng).

b) Quy trình khai phá dữ liệu (EDA)

Mục tiêu: Bước phân tích khám phá dữ liệu (*Exploratory Data Analysis – EDA*) nhằm:

- Hiểu rõ đặc điểm, phân phối và phạm vi giá trị của từng đặc trưng.
- Phát hiện các bất thường (outlier), giá trị thiếu, hoặc sai lệch định dạng.
- Xác định mối tương quan giữa các đặc trưng, từ đó hỗ trợ việc thiết kế mô hình ở các bước tiếp theo.

Bước 1: Thông tin tổng quan. Tập huấn luyện (`train.csv`) chứa:

- $n = 9000$ mẫu.
- $p = 5$ đặc trưng đầu vào dạng số nguyên (`int64`).
- Không có giá trị thiếu (`NaN`).

Dung lượng tệp: ≈ 351.7 KB.

Bước 2: Thống kê mô tả. Bảng 1 trình bày các thống kê cơ bản (giá trị nhỏ nhất, lớn nhất, trung bình, độ lệch chuẩn, các phân vị) của từng đặc trưng.

booktabs float

Bảng 1: Thống kê mô tả các đặc trưng

Đặc trưng	**Mean**	**Std**	**Min**	**25%**	**50%**	**75%**	**Max**
Hours Studied	4.976	2.595	1	3	5	7	9
Previous Scores	69.396	17.370	40	54	69	85	99
Extracurricular Activities	0.494	0.500	0	0	0	1	1
Sleep Hours	6.536	1.696	4	5	7	8	9
Sample Q. Papers Practiced	4.591	2.865	0	2	5	7	9

Bước 3: Kiểm tra giá trị thiếu. Kết quả: Không tồn tại giá trị thiếu ở bất kỳ đặc trưng nào, do đó không cần thực hiện bước điền khuyết (*imputation*).

Bước 4: Phân tích phân phối. Histogram: phân phối giá trị của từng đặc trưng được thể hiện trong Hình 1.

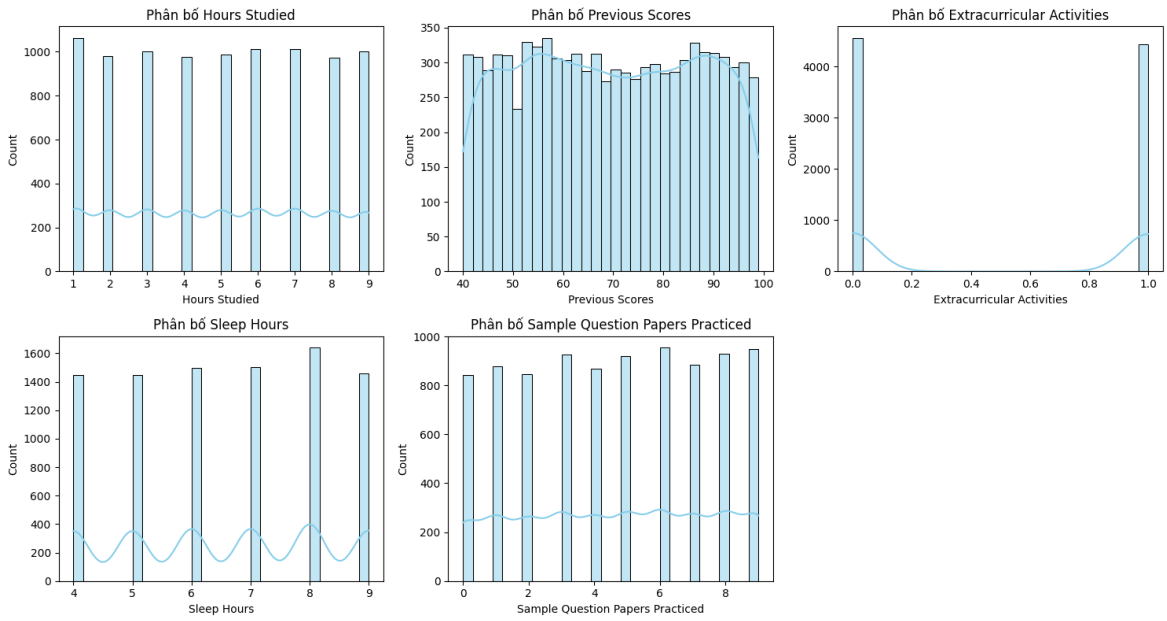

Hình 1: Biểu đồ phân phối các đặc trưng

- **Hours Studied**: phân bố khá đều từ 1–9 giờ, trung bình $\approx$ 5 giờ.
- **Previous Scores**: trải rộng từ 40–99 điểm, trung bình $\approx$ 69.
- **Extracurricular Activities**: gần cân bằng giữa 0 và 1 ($\approx$ 49.4% có tham gia).
- **Sleep Hours**: tập trung nhiều ở khoảng 6–8 tiếng/ngày.
- **Sample Q. Papers Practiced**: phân tán rộng, trung bình $\approx$ 4.6 đề.

Bước 5: Ma trận tương quan. Ma trận tương quan Pearson giữa các đặc trưng được minh họa trong Hình 2.

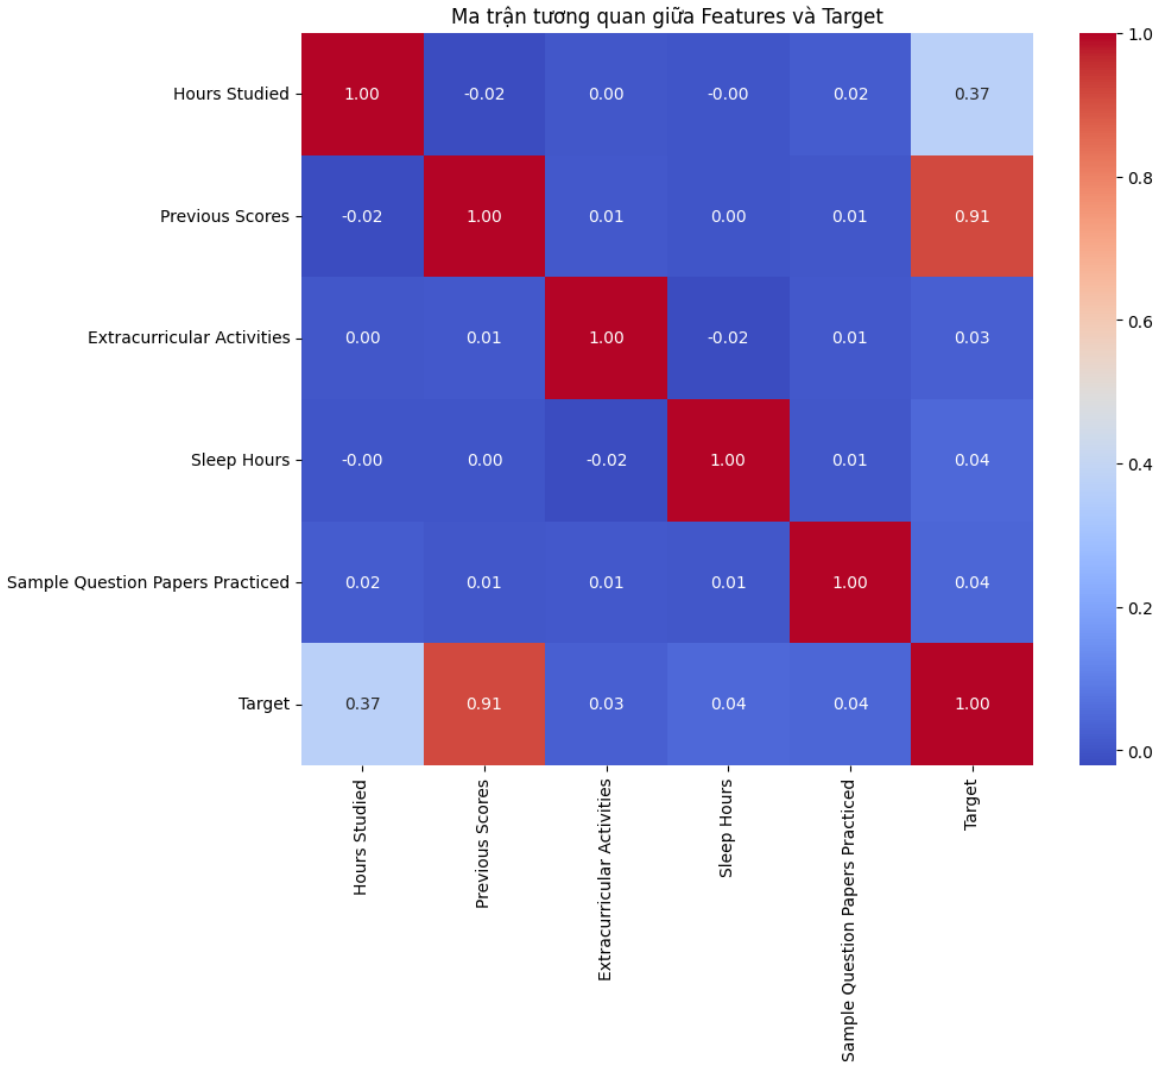

Hình 2: Biểu đồ tương quan giữa các đặc trưng

Hệ số tương quan Pearson giữa các cặp đặc trưng nằm rất gần 0 (Bảng 2), cho thấy các đặc trưng hầu như độc lập với nhau, giúp giảm nguy cơ đa cộng tuyến trong mô hình hồi quy tuyến tính.

- Hệ số tương quan Pearson chỉ đo **mối quan hệ tuyến tính** giữa hai biến. Do đó, nếu tồn tại mối quan hệ phi tuyến, hệ số này có thể không phản ánh đúng thực tế.
- Giá trị tương quan cao (r gần 1 hoặc -1) không đồng nghĩa với *quan hệ nhân quả* (causation). Ví dụ, *Previous Scores* cao có thể phản ánh năng lực tổng thể tốt, nhưng không nhất thiết là nguyên nhân trực tiếp tạo ra *Performance Index* cao.
- Các yếu tố ngoại lai (outliers) có thể làm sai lệch hệ số tương quan, cần kiểm tra dữ liệu kỹ trước khi kết luận.
- Nên kết hợp thêm các phương pháp phân tích khác như hồi quy tuyến tính đa biến, phân tích thành phần chính (PCA) hoặc kiểm định thống kê để xác nhận mối quan hệ giữa các biến.

Bảng 2: Ma trận tương quan Pearson (viết tắt tên cột)

	Hours Studied	Prev Scores	Ex Activities	Sleep Hours	Sample QP	Target
Hours Studied	1.000	-0.020	0.010	0.000	0.010	0.370
Prev Scores	-0.020	1.000	0.010	0.000	0.010	0.910
Ex Activities	0.010	0.010	1.000	-0.020	0.010	0.030
Sleep Hours	0.000	0.000	-0.020	1.000	0.010	0.050
Sample QP	0.010	0.010	0.010	0.010	1.000	0.040
Target	0.370	0.910	0.030	0.050	0.040	1.000

Bước 6. Một số biểu đồ khác Các biểu đồ trực quan được xây dựng nhằm hỗ trợ việc quan sát:

- **Boxplot**: xác định khoảng biến thiên và giá trị ngoại lai. Kết hợp với phân phối, ta nhận xét được:

c) Hours Studied (Số giờ học)

- **Phân bố:** Histogram cho thấy phân bố khá đồng đều từ 1 đến 9 giờ, không có giá trị ngoại lai rõ rệt.
- **Boxplot:** Khoảng tứ phân vị (IQR) hẹp, giá trị trung vị khoảng 5 giờ.
- **Nhận xét:** Dữ liệu phân bố đồng đều, không có thiên lệch rõ. Có khả năng mối tương quan tuyến tính dương với chỉ số hiệu suất.

d) Previous Scores (Điểm trước đó)

- **Phân bố:** Phân bố tương đối đều từ 40 đến gần 100, có một vài khoảng trống nhỏ.
- **Boxplot:** Trung vị khoảng 70, không có ngoại lệ cực đoan.
- **Nhận xét:** Phản ánh năng lực trước đó, nhiều khả năng ảnh hưởng mạnh đến chỉ số hiệu suất.

e) Extracurricular Activities (Hoạt động ngoại khóa)

- **Phân bố:** Cân bằng giữa hai nhóm 0 (không tham gia) và 1 (có tham gia).
- **Boxplot:** Trung vị nhóm tham gia (1) cao hơn nhóm không tham gia (0) một chút.
- **Nhận xét:** Có thể ảnh hưởng nhẹ đến hiệu suất, cần kiểm chứng thêm bằng phân tích thống kê.

f) Sleep Hours (Số giờ ngủ)

- **Phân bố:** Dao động từ 4 đến 9 giờ, phân bố khá đồng đều, không có ngoại lệ.
- **Boxplot:** Trung vị khoảng 7 giờ, IQR hẹp, phần lớn học sinh ngủ từ 6–8 giờ.
- **Nhận xét:** Ổn định, có thể ảnh hưởng gián tiếp đến hiệu suất qua yếu tố sức khỏe.

g) Sample Question Papers Practiced (Số đề mẫu đã luyện)

- **Phân bố:** Đồng đều từ 0 đến 9 đề.
- **Boxplot:** Trung vị khoảng 5 đề, không có ngoại lệ rõ ràng.
- **Nhận xét:** Có thể tác động tích cực đến hiệu suất, đặc biệt khi số đề luyện tăng.

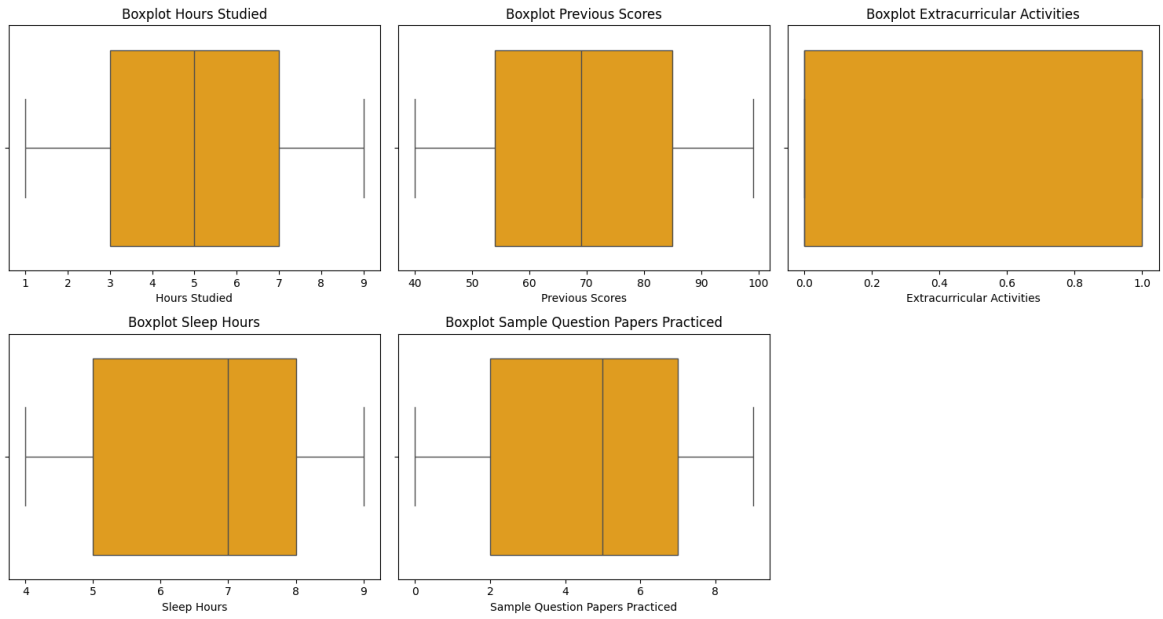

Hình 3: Phân vị

- **Scatter plot với biến mục tiêu**: đánh giá mối quan hệ tuyến tính giữa đặc trưng và chỉ số thành tích.

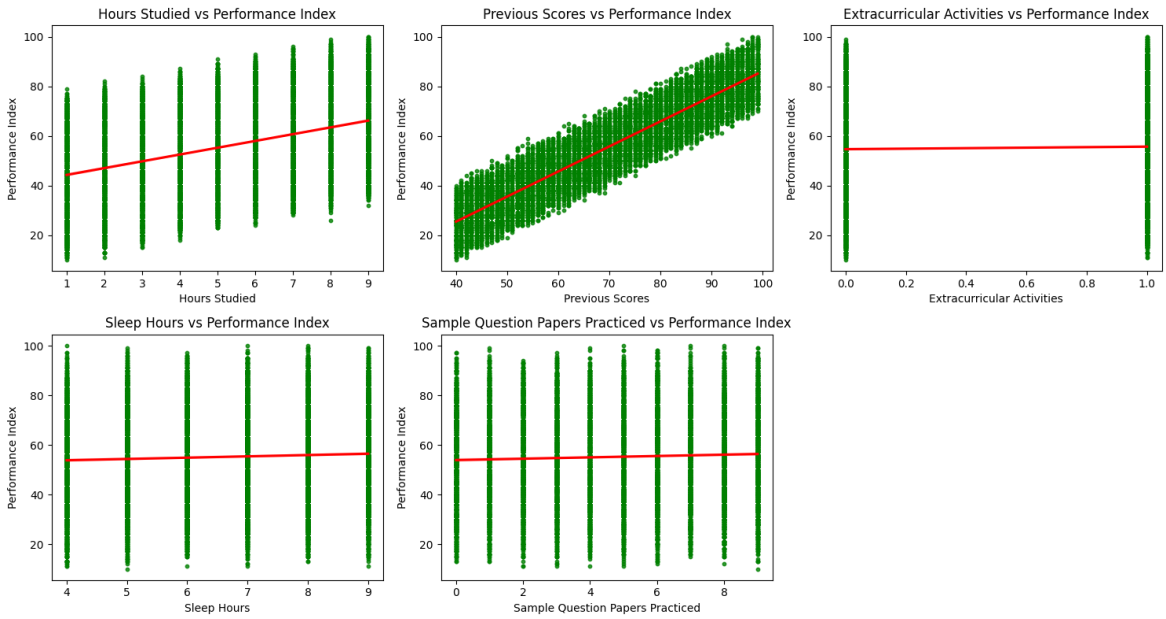

Hình 4: Biểu đồ phân tán

Kết luận EDA. Tập dữ liệu sạch, đầy đủ, các đặc trưng có phân phối hợp lý và ít tương quan chéo. Điều này cho phép triển khai trực tiếp các mô hình hồi quy tuyến tính mà không cần nhiều bước xử lý bổ sung.

3.4 Các mô hình hồi quy tuyến tính

a) Mô hình sử dụng toàn bộ đặc trưng (yêu cầu 2a)

Giải thích và chứng minh công thức hồi quy tuyến tính

Trong mô hình hồi quy tuyến tính, giả sử ta có n mẫu huấn luyện, mỗi mẫu gồm p đặc trưng (features) và một giá trị mục tiêu (target) y. Ta ký hiệu:

$$X \in \mathbb{R}^{n\times p}, \quad y \in \mathbb{R}^n$$

Trong đó:

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Ta thêm một cột 1 vào X để xét hệ số chặn (bias term), khi đó ma trận mới là:

$$\tilde{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \in \mathbb{R}^{n\times(p+1)}$$

Mục tiêu: Tìm vector hệ số $\beta \in \mathbb{R}^{p+1}$ sao cho mô hình

$$\hat{y} = \tilde{X}\beta$$

xấp xỉ tốt nhất y theo nghĩa bình phương tối thiểu.

Hàm mất mát (Least Squares Loss):

$$J(\beta) = \|y - \tilde{X}\beta\|_2^2 = (y - \tilde{X}\beta)^T(y - \tilde{X}\beta)$$

Cực tiểu hàm mất mát: Lấy đạo hàm theo β và cho bằng 0:

$$\frac{\partial J(\beta)}{\partial \beta} = -2\tilde{X}^T y + 2\tilde{X}^T\tilde{X}\beta = 0$$

Suy ra hệ phương trình chuẩn (Normal Equations):

$$\tilde{X}^T\tilde{X}\beta = \tilde{X}^T y$$

Nghiệm của phương trình: Nếu $\tilde{X}^T\tilde{X}$ khả nghịch, nghiệm duy nhất là:

$$\beta = (\tilde{X}^T\tilde{X})^{-1}\tilde{X}^T y$$

Ý nghĩa:

- $(\tilde{X}^T\tilde{X})^{-1}$: ma trận nghịch đảo của ma trận hiệp phương sai (covariance matrix) giữa các đặc trưng.
- $\tilde{X}^T y$: vector tương quan giữa đặc trưng và giá trị mục tiêu.
- Công thức này tìm β sao cho tổng bình phương sai số giữa dự đoán và giá trị thực là nhỏ nhất.

MSE

Định nghĩa: Với dữ liệu huấn luyện $\{(x_i, y_i)\}_{i=1}^n$ và mô hình tuyến tính $\hat{y}_i = f_\theta(x_i)$, *Mean Squared Error* trên mẫu được định nghĩa:

$$\mathrm{MSE}(\theta) \;=\; \frac{1}{n}\sum_{i=1}^{n}\big(y_i - \hat{y}_i\big)^2.$$

Trong hồi quy tuyến tính với ma trận đặc trưng $\tilde{X} \in \mathbb{R}^{n\times(p+1)}$ (đã thêm cột 1 cho bias) và tham số $\beta \in \mathbb{R}^{p+1}$, ta có $\hat{y} = \tilde{X}\beta$ nên:

$$\mathrm{MSE}(\beta) = \frac{1}{n}\| \, y - \tilde{X}\beta \, \|_2^2.$$

MSE $\Rightarrow$ bình phương tối thiểu và phương trình chuẩn. Minh hoạ rằng *cực tiểu hoá MSE* tương đương *bình phương tối thiểu* và dẫn đến phương trình chuẩn (normal equations).
Xét hàm mục tiêu

$$J(\beta) = \frac{1}{n}\big(y - \tilde{X}\beta\big)^\top\big(y - \tilde{X}\beta\big).$$

Lấy đạo hàm theo β và cho bằng 0:

$$\nabla_\beta J(\beta) = \frac{2}{n}\Big(\tilde{X}^\top\tilde{X}\,\beta - \tilde{X}^\top y\Big) = 0 \iff \tilde{X}^\top\tilde{X}\,\beta = \tilde{X}^\top y.$$

Nếu $\tilde{X}^\top\tilde{X}$ khả nghịch, nghiệm duy nhất là

$$\beta^\star = \big(\tilde{X}^\top\tilde{X}\big)^{-1}\tilde{X}^\top y.$$

Trong trường hợp kém điều kiện/hạng thiếu, nghiệm bình phương tối thiểu tổng quát là $\beta^\star = \tilde{X}^+ y$ với $\tilde{X}^+$ là giả nghịch đảo Moore–Penrose.

MSE như ước lượng rủi ro kỳ vọng. Giả sử dữ liệu phát sinh theo $Y = f^\star(X) + \varepsilon$, với $\mathbb{E}[\varepsilon \mid X] = 0$ và $\mathrm{Var}(\varepsilon \mid X) = \sigma^2$. Rủi ro kỳ vọng theo mất mát bình phương là

$$\mathcal{R}(\theta) \;=\; \mathbb{E}\big[(Y - f_\theta(X))^2\big].$$

Khi chỉ có mẫu hữu hạn, *empirical MSE* chính là ước lượng không chệch (up to hằng số) cho rủi ro kỳ vọng (Luật số lớn đảm bảo hội tụ):

$$\mathrm{MSE}(\theta) \;=\; \frac{1}{n}\sum_{i=1}^{n}\big(y_i - f_\theta(x_i)\big)^2 \;\xrightarrow[n\to\infty]{}\; \mathbb{E}\big[(Y - f_\theta(X))^2\big].$$

Do đó, tối ưu MSE trên mẫu là *nguyên lý ước lượng theo rủi ro thực nghiệm* (ERM) cho mất mát bình phương.

Bias–Variance decomposition (chứng minh). Ký hiệu $\hat{f}(X)$ là dự đoán của mô hình (biến ngẫu nhiên theo mẫu train), và $f^\star(X) = \mathbb{E}[Y \mid X]$ là hàm hồi quy thật. Khi đánh giá tại một điểm x cố định, có:

$$\mathbb{E}\big[(Y - \hat{f}(X))^2 \,\big|\, X = x\big] = \underbrace{\big(\mathbb{E}[\hat{f}(x)] - f^\star(x)\big)^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}\big[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2\big]}_{\text{Variance}} + \underbrace{\mathbb{E}\big[(Y - f^\star(x))^2 \mid X = x\big]}_{\text{Noise } \sigma^2}.$$

Chứng minh phác thảo: Viết $Y = f^\star(x) + \varepsilon$, với $\mathbb{E}[\varepsilon \mid X = x] = 0$, rồi cộng trừ $\mathbb{E}[\hat{f}(x)]$:

$$Y - \hat{f}(x) = \big(f^\star(x) - \mathbb{E}[\hat{f}(x)]\big) + \big(\mathbb{E}[\hat{f}(x)] - \hat{f}(x)\big) + \varepsilon.$$

Bình phương hai vế, lấy kỳ vọng có điều kiện theo $X = x$, dùng $\mathbb{E}[\varepsilon] = 0$, tính chất trực giao của các thành phần độc lập kỳ vọng, ta thu được công thức trên. Lấy kỳ vọng theo phân phối X trên toàn miền, suy ra decomposition toàn cục:

$$\mathbb{E}\big[(Y - \hat{f}(X))^2\big] = \mathbb{E}_X\big[\text{Bias}(X)^2\big] + \mathbb{E}_X\big[\text{Var}(\hat{f}(X))\big] + \sigma^2.$$

Hệ quả: MSE nhỏ khi bias và phương sai của mô hình đều nhỏ; đây là gốc rễ của thoả hiệp *bias–variance trade-off.*

Kết quả Mô hình hồi quy toàn bộ đặc trưng

$$\widehat{\text{Student Performance}} = -33.969 + 2.852 \cdot \text{HS} + 1.018 \cdot \text{PS} + 0.604 \cdot \text{EA} + 0.474 \cdot \text{SH} + 0.192 \cdot \text{SQP}$$

MSE: 4.093

Trường hợp 1 đặc trưng (dùng cho Câu 2b). Với một đặc trưng $x \in \mathbb{R}^n$, mô hình $\hat{y} = \theta_0 + \theta_1 x$, nghiệm đóng dạng của bình phương tối thiểu là:

$$\theta_1^\star = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \qquad \theta_0^\star = \bar{y} - \theta_1^\star \bar{x},$$

trong đó $\bar{x} = \frac{1}{n}\sum_i x_i$, $\bar{y} = \frac{1}{n}\sum_i y_i$. Công thức này thu được trực tiếp từ việc cực trị hoá MSE theo θ_0, θ_1 (đạo hàm riêng và giải hệ).

So sánh ngắn gọn MSE so với MAE. MSE *khả vi* ở mọi nơi và *phạt mạnh* sai số lớn (do bình phương), phù hợp với nghiệm đóng dạng và tối ưu hoá mượt mà; MAE bền vững hơn với ngoại lai nhưng không khả vi tại 0, không có nghiệm đóng dạng tương tự. Lựa chọn MSE là chuẩn mực cho hồi quy tuyến tính cổ điển.

b) Chọn đặc trưng tốt nhất với K-fold Cross Validation (yêu cầu 2b)

Giải thích phương pháp K-fold Cross-Validation để chọn đặc trưng tốt nhất

Bài toán đặt ra: Ta có tập dữ liệu huấn luyện gồm n mẫu $\{(x_i, y_i)\}_{i=1}^n$ với p đặc trưng đầu vào:

$$X = [X^{(1)}, X^{(2)}, \ldots, X^{(p)}],$$

trong đó $X^{(j)} \in \mathbb{R}^n$ là vector giá trị của đặc trưng thứ j. Mục tiêu của Câu 2b là:

Xây dựng và đánh giá p mô hình hồi quy tuyến tính, mỗi mô hình chỉ dùng duy nhất một đặc trưng $X^{(j)}$, sau đó chọn ra đặc trưng $j^\star$ sao cho mô hình đạt *Mean Squared Error* (MSE) nhỏ nhất.

Lý do sử dụng Cross-Validation. Nếu chỉ tách dữ liệu thành một cặp *train/test* duy nhất, kết quả đánh giá có thể phụ thuộc mạnh vào cách chia dữ liệu (variance cao). *K-fold cross-validation* giúp:

- Giảm độ lệch do ngẫu nhiên chia dữ liệu.
- Sử dụng được toàn bộ dữ liệu cho cả huấn luyện và kiểm định (mỗi mẫu được dùng để test đúng 1 lần).
- Cho ước lượng MSE ổn định và tổng quát hơn.

Cơ chế K-fold Cross-Validation. Cho trước $k \geq 5$ (trong bài chọn $k = 5$):

1. Chia ngẫu nhiên tập dữ liệu $\{1, 2, \ldots, n\}$ thành k phần gần bằng nhau: $F_1, F_2, \ldots, F_k$.
2. Với mỗi fold $t \in \{1, \ldots, k\}$:
   - Dùng F_t làm tập *validation* (kiểm định).
   - Dùng $\bigcup_{s \neq t} F_s$ làm tập *train*.
   - Huấn luyện mô hình hồi quy tuyến tính 1 đặc trưng $X^{(j)}$ trên tập train.
   - Dự đoán trên tập validation, tính $\mathrm{MSE}_t^{(j)}$.
3. Lấy *MSE trung bình* trên k folds:
$$\overline{\mathrm{MSE}}^{(j)} = \frac{1}{k} \sum_{t=1}^{k} \mathrm{MSE}_t^{(j)}.$$

Chọn đặc trưng tốt nhất. Sau khi tính $\overline{\mathrm{MSE}}^{(j)}$ cho mọi $j = 1, \ldots, p$, ta chọn:

$$j^\star = \arg \min_{j \in \{1, \ldots, p\}} \overline{\mathrm{MSE}}^{(j)}.$$

Đặc trưng $X^{(j^\star)}$ được coi là *best feature* vì mô hình tuyến tính một biến này cho sai số bình phương trung bình nhỏ nhất trong cross-validation.

Tại sao có thể áp dụng phương pháp này.

- **Tính nhất quán**: Cross-validation cung cấp ước lượng không chệch (asymptotically unbiased) của sai số kỳ vọng $\mathbb{E}[(Y - \hat{f}(X))^2]$ khi kích thước mẫu lớn.
- **So sánh công bằng**: Vì mỗi đặc trưng được đánh giá bằng cùng một quy trình chia dữ liệu và cùng chỉ số MSE, kết quả là so sánh trực tiếp và công bằng giữa các đặc trưng.
- **Độc lập mô hình**: Phương pháp này không yêu cầu giả định đặc biệt ngoài khả năng huấn luyện mô hình hồi quy tuyến tính với từng đặc trưng.

Quy trình áp dụng trong bài toán.

1. Duyệt qua từng đặc trưng $X^{(j)}$, tạo ma trận đặc trưng 1 cột.
2. Thực hiện 5-fold cross-validation như mô tả trên để thu được $\overline{\text{MSE}}^{(j)}$.
3. Chọn đặc trưng $j^\star$ với MSE trung bình nhỏ nhất.
4. Huấn luyện lại mô hình 1 biến này trên toàn bộ tập train để lấy tham số cuối cùng (θ_0, θ_1).
5. Đánh giá trên tập test để thu được MSE cuối cùng báo cáo.

Ý nghĩa thực tế. Việc chọn đặc trưng tốt nhất theo cách này giúp xác định biến đơn lẻ có sức mạnh dự đoán cao nhất, từ đó:

- Cung cấp thông tin trực quan về mức độ quan trọng của từng đặc trưng.
- Có thể dùng làm baseline để so sánh với các mô hình đa biến (Câu 2a, 2c).

Sử dụng $k = 5$, shuffle dữ liệu trước mỗi lần chia fold. Kết quả:

Bảng 3: MSE trung bình của từng đặc trưng (Cross Validation)

Đặc trưng	**MSE trung bình**
Hours Studied (HS)	318.026
Previous Scores (PS)	60.119
Extracurricular Activities (EA)	368.268
Sleep Hours (SH)	367.601
Sample QP Practiced (SQP)	367.704

Kết quả Mô hình hồi quy 1 đặc trưng tốt nhất

$$\widehat{\text{Student Performance}} = -14.989 + 1.011 \cdot \text{PS}$$

Mục tiêu. Ở yêu cầu này, sinh viên được phép thiết kế các mô hình kết hợp đặc trưng, có thể áp dụng biến đổi hoặc tạo đặc trưng mới, với mục tiêu tìm ra mô hình có độ chính xác cao hơn so với các mô hình ở Câu 2a và 2b.

Lý do lựa chọn đặc trưng. Dựa trên kết quả EDA (Mục **??**) và kết quả của Câu 2b, đặc trưng *Previous Scores* có tương quan cao nhất với biến mục tiêu. Do đó, trong các mô hình thử nghiệm, đặc trưng này được đưa vào kết hợp với các đặc trưng khác nhằm tận dụng tối đa thông tin.

Ý tưởng lựa chọn mô hình. Dựa trên kết quả phân tích khám phá dữ liệu (EDA) và ma trận tương quan Pearson (Hình 2), biến `Previous Scores` có tương quan rất cao với biến mục tiêu `Target` ($r \approx 0.91$), tiếp theo là `Hours Studied` ($r \approx 0.37$). Các biến còn lại có mức tương quan thấp (< 0.1), do đó chúng ít đóng góp trực tiếp trong mô hình tuyến tính bậc nhất. Tuy nhiên, việc chỉ dựa vào tương quan tuyến tính có thể bỏ sót mối quan hệ phi tuyến hoặc tương tác giữa các biến. Vì vậy, trong yêu cầu 2c, ba mô hình được đề xuất như sau:

- **Mô hình 1 (Tuyến tính hai đặc trưng):**

$$y = \theta_0 + \theta_1 \cdot \text{HS} + \theta_2 \cdot \text{PS}$$

Trong đó HS là `Hours Studied`, PS là `Previous Scores`. Mục tiêu: khai thác đồng thời hai biến có tương quan cao và trung bình với `Target`.

- **Mô hình 2 (Kết hợp phi tuyến bậc hai):**

$$y = \theta_0 + \theta_1 \cdot (\text{HS})^2 + \theta_2 \cdot \text{PS}$$

Mô hình này thử thêm thành phần bình phương để nắm bắt mối quan hệ phi tuyến tiềm ẩn của `Hours Studied` với thành tích.

- **Mô hình 3 (Tương tác hai biến):**

$$y = \theta_0 + \theta_1 \cdot (\text{HS} \times \text{EA}) + \theta_2 \cdot \text{EA}$$

Trong đó EA là `Extracurricular Activities`. Mục tiêu: kiểm tra xem hoạt động ngoại khoá có tương tác cộng hưởng hoặc làm giảm hiệu quả của giờ học đối với kết quả hay không.

Phương pháp đánh giá. Tất cả các mô hình được đánh giá bằng **k-fold Cross Validation** với $k = 5$. Trong mỗi vòng lặp:

1. Dữ liệu được **xáo trộn ngẫu nhiên** để tránh sai lệch do thứ tự ban đầu.
2. Chia dữ liệu thành 5 phần bằng nhau; mỗi phần lần lượt được dùng làm tập kiểm tra, 4 phần còn lại làm tập huấn luyện.
3. Huấn luyện mô hình bằng công thức bình phương tối thiểu:

$$\boldsymbol{\theta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

4. Tính sai số trung bình bình phương (MSE) trên tập kiểm tra.

MSE trung bình qua k lần lặp là thước đo hiệu suất của mô hình.

Bảng 4: Kết quả Cross Validation cho các mô hình 2c

Mô hình	Đặc trưng sử dụng	MSE trung bình (CV)
Mô hình 1	HS, PS	5.203
Mô hình 2	HS^2, PS	7.790
Mô hình 3	HS×EA, EA	341.970

Kết quả thực nghiệm.

Phân tích và nhận xét. Kết quả ở Bảng 4 cho thấy **Mô hình 1** đạt MSE trung bình thấp nhất (59.842), vượt nhẹ so với Mô hình 2 và rõ rệt hơn so với Mô hình 3. Điều này có thể giải thích như sau:

- Việc thêm thành phần bình phương ($\texttt{HS}^2$) trong Mô hình 2 không cải thiện mà còn làm MSE tăng nhẹ, chứng tỏ quan hệ giữa `Hours Studied` và `Target` gần như tuyến tính trong tập dữ liệu này.
- Mô hình 3 sử dụng `Extracurricular Activities` và tương tác với `Hours Studied` cho MSE cao hơn đáng kể, có thể do biến EA có tương quan thấp với mục tiêu và tương tác này không mang ý nghĩa thống kê.

Mô hình tối ưu và công thức cuối cùng. Huấn luyện lại Mô hình 1 trên toàn bộ tập huấn luyện, ta thu được:

$$\hat{y} = \theta_0 + \theta_1 \cdot \mathrm{HS} + \theta_2 \cdot \mathrm{PS}$$

Trong đó:

$$\theta_0 = -29.747, \quad \theta_1 = 2.856, \quad \theta_2 = 1.018$$

Kiểm tra trên tập `test.csv` cho MSE = 5.393, xác nhận tính ổn định của mô hình.

4 Kết quả và kết luận

5 Tài liệu

[1] Giải thích công thức hồi quy tuyến tính và MSE: Introduction to Applied Linear Algebra chương 13 - Stephen Lieven

[2] Các bước tiền xử lí EDA: Intro to Exploratory data analysis (EDA) in Python

[3] Giải thích biểu đồ: Exploratory Data Analysis

6 Acknowledgement

Em xin chân thành cảm ơn các Thầy **Nguyễn Đình Thúc, Trần Hà Sơn, Nguyễn Văn Quang Huy, Nguyễn Ngọc Toàn** đã tận tình hướng dẫn trong suốt quá trình học tập, cung cấp cho em những kiến thức nền tảng vững chắc để em có thể hoàn thành đồ án này.
Ngoài những kiến thức đã học và các tài liệu tham khảo được liệt kê, trong quá trình thực hiện, em có sử dụng công cụ AI ChatGPT như một trợ lý hỗ trợ giải thích các cú pháp hàm, sắp xếp ý tưởng và hoàn thiện cách diễn đạt câu từ, nhằm đảm bảo báo cáo được trình bày một cách rõ ràng và mạch lạc nhất.